

Replicação e Extensão Neuro-Simbólica do Benchmark SONBRA para Classificação de Gêneros Musicais Brasileiros

João Lucas de Brito Ramalho Silva
Universidade Federal de Campina Grande
Programa de Pós-Graduação em Ciência da Computação
Campina Grande, PB, Brasil
joaolucas.silva@copin.ufcg.edu.br

Resumo

Este trabalho relata a execução completa de uma replicação metodológica do *benchmark* de classificação de gêneros musicais brasileiros estabelecido por Ribeiro et al. [4] com o *dataset* SONBRA, estendida por uma camada neuro-simbólica sobre o Perceptron Multicamadas (MLP). O experimento adota um desenho fatorial com **cinco repetições** independentes (sementes aleatórias distintas) e comparações pareadas por semente, permitindo tratamento estatístico formal dos efeitos. O primeiro resultado quantifica o *data leakage* por fragmentação de música: um MLP treinado com divisão aleatória por fragmento atinge $92,67\% \pm 0,71$ de acurácia, ante $79,57\% \pm 0,87$ sob divisão estratificada por música (*StratifiedGroupK-Fold*) — uma inflação média de **13,10 pontos percentuais** (IC 95%: [11,55; 14,65]; $t(4)=23,47$, $p<0,001$), atribuível exclusivamente ao vazamento e consistente nas cinco repetições. O segundo avalia uma camada simbólica com seis regras de domínio musicológico acoplada como pós-processador probabilístico do MLP: o efeito agregado é **estatisticamente indistinguível de zero** ($+0,02$ p.p.; IC 95%: $[-0,14; +0,18]$; $p=0,56$). A análise por gênero revela que esse resultado nulo não decorre de inação, e sim do cancelamento entre um ganho na Bossa Nova ($+0,91$ p.p.) e uma degradação sistemática no Samba ($-1,11$ p.p., único gênero com sinal consistente nas cinco sementes). Um pipeline de explicabilidade (importância por permutação, análise de pares confundidos e árvore *surrogate*) identifica os coeficientes MFCC como os descritores de maior poder discriminativo, ajudando a explicar o limite da camada simbólica. Os resultados refutam a hipótese de ganho agregado, delimitam com precisão o escopo de aplicabilidade da abordagem neuro-simbólica e são acompanhados de um pacote de artefatos completo para reprodução independente.

Keywords

SONBRA; Perceptron Multicamadas; classificação de gêneros musicais; recuperação de informação musical; inteligência artificial neuro-simbólica; *data leakage*; explicabilidade; desenho experimental; teste de hipótese

1 Introdução

A música constitui uma das formas mais ricas de expressão cultural, refletindo contextos sociais, históricos e geográficos distintos [4]. No Brasil, essa diversidade é particularmente marcante: gêneros como Samba, Forró, Bossa Nova, Funk e Sertanejo possuem características acústicas, rítmicas e harmônicas próprias que os diferenciam tanto entre si quanto dos estilos musicais internacionais predominantes nos grandes *datasets* de pesquisa.

A classificação automática de gêneros musicais (*Music Genre Classification* — MGC) é uma tarefa central no campo da Recuperação de Informação Musical (*Music Information Retrieval* — MIR), com aplicações diretas em plataformas de *streaming*, sistemas de recomendação e ferramentas de organização de acervos digitais [5]. Contudo, *datasets* amplamente utilizados na literatura — como o GTZAN [6] e o FMA [2] — concentram-se predominantemente em gêneros de origem anglo-saxônica, com pouca ou nenhuma representação de estilos brasileiros [1].

Para suprir essa lacuna, Ribeiro et al. [4] criaram e disponibilizaram publicamente o SONBRA, um *dataset* anotado e balanceado voltado exclusivamente a gêneros musicais brasileiros. O conjunto reúne 10.000 fragmentos de áudio de 30 segundos distribuídos uniformemente entre oito gêneros — Bossa Nova, Forró, Forró Piseiro, Funk, Pagode, Samba, Samba-Enredo e Sertanejo —, descritos por 785 parâmetros acústicos extraídos com a biblioteca Librosa [3]. O *benchmark* conduzido pelos autores avaliou sete algoritmos de aprendizado de máquina supervisionado, estabelecendo um ponto de comparação sólido para pesquisas futuras.

Esse *benchmark*, porém, deixa duas questões metodológicas em aberto. A primeira diz respeito à divulgação incompleta dos hiperparâmetros finais dos modelos, o que impede uma reprodução fiel das condições de treinamento. A segunda — reconhecida pelos próprios autores, mas não quantificada por eles — é o risco de *data leakage* (vazamento de dados): como cada faixa musical origina cinco fragmentos distintos, uma divisão aleatória dos 10.000 fragmentos pode inserir trechos de uma mesma música simultaneamente em treino e em teste, inflando artificialmente a acurácia ao permitir que o modelo memorize assinaturas artísticas em vez de aprender padrões genuínos do gênero [4]. Essas duas lacunas motivam o presente trabalho, que se configura como **replicação metodológica**: adota-se a mesma abordagem geral do artigo original, com a correção explícita do protocolo de divisão e a mensuração direta do efeito do vazamento.

O foco da replicação recai sobre o Perceptron Multicamadas (MLP), único representante de redes neurais artificiais no *benchmark* de Ribeiro et al. Além da replicação, este trabalho investiga (i) o que o modelo efetivamente aprendeu, por meio de um pipeline de explicabilidade, e (ii) se o acoplamento de uma camada de IA simbólica — composta por regras derivadas de análise estatística e de conhecimento musicológico — pode complementar as predições do MLP, especialmente nos gêneros que o artigo original aponta como mais difíceis de classificar.

O experimento adota um desenho com repetições e comparações pareadas, descrito na Seção 2.2, de modo que cada efeito reportado venha acompanhado de estimativa de incerteza e teste de hipótese.

Essa escolha não é ornamental: como se verá, ela é o que separa um dos achados aparentes deste *dataset* de um artefato de uma execução particular.

As seguintes questões de pesquisa orientaram o experimento:

- **QP1:** É possível replicar a acurácia do MLP reportada por Ribeiro et al. [4] com desvio inferior a dois pontos percentuais, corrigindo o protocolo de divisão para eliminar *data leakage*? Qual a magnitude do vazamento, caso ele não seja corrigido?
- **QP2:** Quais características acústicas apresentam maior poder discriminativo para os oito gêneros do SONBRA, tanto sob análise estatística univariada quanto sob a ótica do que o próprio MLP aprendeu?
- **QP3:** A incorporação de uma camada simbólica de domínio altera significativamente o desempenho classificatório do MLP, especialmente nos gêneros de maior dificuldade?

A hipótese de pesquisa que orienta o projeto de mestrado ao qual este artigo se conecta é: *a adição de uma camada de IA simbólica ao pipeline de classificação de gêneros musicais brasileiros melhora a acurácia, especialmente nos gêneros de classificação mais difícil*. As QP1–QP3 operacionalizam essa hipótese em perguntas testáveis com os dados e o modelo disponíveis.

QP1 e QP3 são formuladas como hipóteses estatísticas testáveis sobre a acurácia de teste, avaliadas com $\alpha=0,05$:

- $H_0^{(1)}$: não há diferença na acurácia média entre o protocolo de divisão por fragmento e o protocolo de divisão por música. $H_1^{(1)}$: há diferença.
- $H_0^{(2)}$: não há diferença na acurácia média entre o MLP puro e o MLP acoplado à camada simbólica. $H_1^{(2)}$: há diferença.

Ambas as hipóteses são bilaterais: no caso do *leakage*, embora a direção do efeito seja teoricamente previsível, o interesse está na sua *magnitude*; no caso da camada simbólica, um efeito negativo é tão informativo quanto um positivo, e o desenho não deve pressupor a direção que a hipótese do mestrado espera.

O restante deste artigo está organizado da seguinte forma: a Seção 2 descreve a metodologia; a Seção 3 apresenta e discute os resultados; a Seção 4 trata das ameaças à validade; a Seção 5 conclui o trabalho; e a Seção 6 descreve os artefatos e o procedimento de reprodução.

2 Metodologia

2.1 Tipo de Experimento e Questões de Pesquisa

Este trabalho realiza uma **replicação metodológica**, tomando como referência Ribeiro et al. [4]. A opção pela replicação, no lugar da reprodução estrita, justifica-se por dois motivos: os hiperparâmetros finais não foram divulgados, tornando inviável recriar as condições exatas de treinamento; e o trabalho introduz uma extensão (a camada neuro-simbólica) que altera o escopo experimental. Por razões de prazo e foco na hipótese neuro-simbólica, a replicação está restrita ao MLP, único modelo do *benchmark* baseado em redes neurais artificiais.

2.2 Desenho Experimental

Variáveis independentes (VI). O experimento manipula dois fatores, ambos categóricos e sob controle direto do pesquisador:

- **VI₁ — protocolo de divisão dos dados**, com dois níveis: *por fragmento* (divisão aleatória sobre as 10.000 amostras, permitindo *data leakage*) e *por música* (divisão agrupada pelas 1.993 faixas de origem, com 0% de sobreposição garantida).
- **VI₂ — camada simbólica**, com dois níveis: *ausente* (predição do MLP aceita sem modificação) e *presente* (pós-processamento probabilístico pelas seis regras de domínio).

Variável dependente (VD). A **acurácia de classificação no conjunto de teste**, medida como a proporção de fragmentos corretamente classificados. A acurácia por gênero é registrada como variável dependente secundária, usada apenas em análise exploratória.

Fatores fixos (variáveis de controle). Mantidos constantes em todas as condições para isolar o efeito das VI: o conjunto de características (Mel + MFCC + Tempogram, 532 colunas), a arquitetura e os hiperparâmetros do MLP (ativação *tanh*, camadas ocultas (200,100), otimizador *adam*, $\alpha=0,0001$, $\max_iter = 500$, *early stopping* com janela de 15 épocas), as proporções de divisão (70% desenvolvimento / 30% teste), o limiar de confiança da camada simbólica ($\tau=0,65$) e as seis regras simbólicas com seus limiares. A arquitetura e as regras foram selecionadas **uma única vez**, em etapa preparatória descrita nas Seções 2.5 e 2.7, e não são re-selecionadas a cada repetição — o alvo da repetição é a variação estocástica do *pipeline final*, não do processo de seleção de modelo.

Condições experimentais. Os dois fatores não são cruzados em um desenho fatorial completo 2×2 : a condição *por fragmento* $\times$ *camada presente* é deliberadamente omitida, por não ter interpretação útil — avaliar a camada simbólica sobre um modelo cuja acurácia é sabidamente inflada por vazamento mediria o efeito das regras sobre um artefato, não sobre o fenômeno de interesse. Restam, portanto, **três condições**:

- (A) Divisão por fragmento, sem camada simbólica;
- (B) Divisão por música, sem camada simbólica;
- (C) Divisão por música, com camada simbólica.

O contraste **A vs. B** isola o efeito do protocolo de divisão (QP1); o contraste **B vs. C** isola o efeito da camada simbólica (QP3).

Repetições e randomização. O experimento foi repetido **cinco vezes** ($n=5$). A unidade de randomização é a **semente aleatória**, que governa simultaneamente a partição dos dados e a inicialização dos pesos do MLP — as duas fontes de variação estocástica do pipeline. As cinco sementes utilizadas foram {42, 7, 123, 2024, 99}, fixadas *a priori* e reportadas integralmente, de modo que nenhuma execução seja descartada *post hoc*.

Dentro de cada repetição, **a mesma semente é aplicada às três condições**, o que torna o desenho **pareado por semente**: as condições B e C compartilham exatamente o mesmo modelo treinado e o mesmo conjunto de teste, diferindo apenas pela aplicação das regras; A e B compartilham a semente e todos os fatores fixos, diferindo apenas pelo critério de agrupamento da divisão. O pareamento remove a variabilidade entre sementes do termo de erro e aumenta substancialmente o poder do teste — decisão importante dado o n reduzido.

Análise estatística. Para cada contraste calcula-se a diferença pareada por semente. Reportam-se média, desvio-padrão e intervalo de confiança de 95% construído pela distribuição t de Student com 4 graus de liberdade. A normalidade das diferenças é verificada por **Shapiro-Wilk**; não sendo rejeitada, o teste primário é o t de Student pareado; sendo rejeitada, adota-se o **Wilcoxon signed-rank** como alternativa não paramétrica. Ambos os testes são reportados em todos os casos, por transparência. O tamanho de efeito é expresso pelo d de Cohen para amostras pareadas. Adota-se $\alpha=0,05$ em testes bilaterais.

2.3 Dataset

O *dataset* utilizado é o SONBRA [4], disponível publicamente no Zenodo¹. O conjunto é composto por 10.000 amostras de fragmentos de áudio de 30 segundos, agrupadas em 1.993 faixas únicas coletadas do YouTube (oito nomes de música duplicados entre dois gêneros foram colapsados em um único agrupamento por arquivo, ao qual se atribui um único gênero pela moda de seus fragmentos), distribuídas uniformemente entre oito gêneros brasileiros (1.250 amostras por gênero). Cada amostra é descrita por 785 parâmetros acústicos obtidos com a biblioteca Librosa [3], a partir de 14 extratores: Chroma CENS, Chroma CQT, Chroma STFT, Fourier Tempogram, Mel-spectrogram, MFCC, RMS, Spectral Bandwidth, Spectral Centroid, Spectral Roll-Off, Tempogram, Tonnetz, ZCR e ZCR Sum. Este trabalho utiliza a versão de média das características (*mean*), em arquivos no formato Parquet.

2.4 Controle de Data Leakage

O SONBRA extrai cinco fragmentos por faixa (início, *middle_1*, meio, *middle_2* e fim). Uma divisão aleatória dos 10.000 fragmentos pode inserir segmentos de uma mesma música simultaneamente nos conjuntos de treino e teste, inflando artificialmente a acurácia ao permitir que o modelo memorize assinaturas artísticas no lugar de padrões do gênero — problema reconhecido pelos próprios autores do *dataset*, mas não quantificado por eles [4].

Este é o fator VI₁ do desenho (Seção 2.2), com dois níveis: (i) **divisão aleatória por fragmento**, replicando literalmente o procedimento descrito no artigo original; e (ii) **divisão estratificada por música**, na qual os 10.000 fragmentos são agrupados pelas 1.993 faixas que os originaram e a divisão é realizada no nível da faixa, garantindo 0% de sobreposição de músicas entre os conjuntos. As proporções seguem as do artigo original: desenvolvimento (70%, $n=7.000$) e teste (30%, $n=3.000$). A divisão por música emprega StratifiedGroupKFold, com `groups=arquivo`, de modo que a mesma música nunca apareça em conjuntos distintos; a divisão por fragmento emprega `train_test_split` estratificado convencional, sem essa restrição. Em cada repetição, a semente da condição é aplicada a todos os componentes estocásticos.

Como **verificação de manipulação** — isto é, para confirmar que o fator foi de fato manipulado como pretendido —, cada execução mede a taxa de sobreposição de músicas entre os conjuntos de desenvolvimento e teste. A métrica reporta o percentual das músicas presentes no conjunto de teste que também aparecem no conjunto de desenvolvimento. Sob a divisão por música, essa taxa é de **0,00%** por construção, e o valor é assegurado por `assert` em tempo de

execução; sob a divisão por fragmento, ela é medida empiricamente e reportada na Seção 3.1. A comparação direta entre os dois níveis é o contraste A vs. B.

2.5 Seleção de Características e Configuração do MLP

A arquitetura do MLP foi definida em uma **etapa preparatória**, anterior e externa ao experimento repetido, cujo produto é um conjunto de fatores fixos (Seção 2.2). Foram avaliadas as duas combinações de características identificadas como mais informativas pelo artigo original: (1) Mel + MFCC + Tempogram (532 colunas) e (2) Chroma CENS + Mel + Tempogram (524 colunas). Para cada combinação, uma busca em grade (*grid search*) sobre os hiperparâmetros do MLP foi conduzida via validação cruzada estratificada por música ($k=10$) no conjunto de treino. Os hiperparâmetros pesquisados foram função de ativação (*tanh*, *relu*) e tamanhos das camadas ocultas $\{(100), (200), (100,50), (200,100)\}$.

A combinação Mel + MFCC + Tempogram com arquitetura (200,100) neurônios e ativação *tanh* apresentou a melhor acurácia média em validação cruzada (78,32%) e foi selecionada. Os demais hiperparâmetros foram fixados: otimizador *adam*, $\alpha = 0,0001$, `learning_rate_init = 0,001`, `max_iter = 500`, `early_stopping = True` com janela de 15 épocas sem melhoria.

Essa busca em grade foi executada **uma única vez e não é repetida a cada semente**. A decisão é deliberada e tem duas justificativas. A primeira é de escopo: o objeto da repetição é a variação estocástica do pipeline final — partição dos dados e inicialização/treino da rede —, que é precisamente o que as hipóteses $H^{(1)}$ e $H^{(2)}$ interrogam; re-selecionar a arquitetura a cada semente transformaria a arquitetura em uma variável aleatória e confundiria o efeito das VI com o efeito da seleção de modelo. A segunda é de custo: 16 configurações $\times$ 10 *folds* $\times$ 5 sementes seria proibitivo no ambiente disponível sem retorno proporcional. A consequência dessa escolha para a validade dos resultados é declarada explicitamente na Seção 4.

A mesma configuração é usada nas três condições experimentais, isolando o efeito das variáveis de interesse.

2.6 Explicabilidade do MLP (XAI)

Para responder a QP2 além da análise estatística univariada, aplicou-se ao modelo treinado sob o protocolo corrigido (Seção 2.4) um pipeline de explicabilidade com três técnicas complementares, executadas sobre o conjunto de teste:

- (1) **Importância por permutação:** para cada uma das 532 *features*, os valores são embaralhados entre as amostras de teste e mede-se a queda resultante na acurácia do MLP (10 repetições por *feature*). Quanto maior a queda, maior a dependência do modelo em relação àquela variável.
- (2) **Análise de pares confundidos:** para os quatro pares de gêneros mais frequentemente trocados pelo modelo, compara-se a média de cada *feature* entre as amostras corretamente classificadas e as confundidas, normalizada pelo desvio-padrão do grupo correto, isolando as variáveis que mais se deslucem nos casos de erro.
- (3) **Árvore surrogate:** uma árvore de decisão rasa (profundidade 4) é treinada para *imitar* as predições do MLP (não os

¹<https://doi.org/10.5281/zenodo.17958966>

rótulos verdadeiros), produzindo uma aproximação legível do comportamento do modelo, cuja fidelidade é medida pela concordância entre as predições da árvore e as do MLP.

2.7 Camada de IA Simbólica

A camada simbólica opera como pós-processador probabilístico do MLP, seguindo a arquitetura:

- (1) O MLP processa cada trecho de áudio e produz um **vetor de probabilidades** $\mathbf{p} \in [0, 1]^8$ — um valor entre 0 e 1 para cada um dos oito gêneros, indicando o grau de confiança do modelo em cada classe.
- (2) Se a maior probabilidade do vetor não supera o **limiar de confiança** τ — ou seja, o modelo está “em dúvida” entre os candidatos —, a camada simbólica é ativada; caso contrário, a predição do MLP é aceita sem modificação.
- (3) Cada regra simbólica que se aplica ao perfil acústico da amostra **multiplica** a probabilidade do gênero-alvo por um fator de reforço específico da regra ($\times 1,20$ a $\times 1,35$, conforme a Tabela 1) e a probabilidade de cada gênero concorrente listado na regra por um fator de penalidade ($\times 0,70$ a $\times 0,80$), rebalanceando as probabilidades com base no conhecimento musical.
- (4) O vetor $\mathbf{p}$ ajustado é **renormalizado** para continuar somando 1,0, preservando sua interpretação probabilística.
- (5) A predição final é o gênero de maior probabilidade após o ajuste: $\hat{y} = \arg \max(\mathbf{p})$.

O limiar $\tau=0,65$ foi escolhido, em vez do valor *default* da implementação ($\tau=0,50$), por fornecer um volume maior de intervenções ($8,76\% \pm 0,28$ das amostras de teste, nas cinco repetições) para avaliação — com o limiar *default*, a fração de amostras abaixo do limiar de confiança é consideravelmente menor, dado que o MLP atinge confiança $\geq 0,50$ na grande maioria dos casos.

As regras e seus limiares constituem **fatores fixos** do desenho: são conhecimento de domínio, derivados uma única vez na etapa preparatória, e **não são re-derivados a cada semente**. O que varia entre repetições é apenas o MLP sobre o qual as regras atuam e o conjunto de teste ao qual são aplicadas. Essa escolha mantém a camada simbólica como um tratamento constante — condição necessária para que o contraste B vs. C meça o efeito *das regras*, e não o efeito de recalibrá-las.

As seis regras simbólicas foram derivadas em duas etapas: (i) análise estatística de *features* escalares no conjunto de **treino** — ZCR, RMS, centroide espectral, *roll-off* e, exploratoriamente, os seis componentes do Tonnetz —, calculando média, mediana e quartis por gênero; e (ii) conhecimento musicológico dos gêneros brasileiros conforme documentado em [4]. O Tonnetz não apresentou separação clara entre os gêneros-alvo e foi descartado nesta etapa; as seis regras finais condicionam-se apenas em ZCR, RMS, centroide espectral e *roll-off*. Os limiares derivam das estatísticas por gênero nos dados de treino — em geral, o ponto médio entre as médias dos gêneros-alvo. A Tabela 1 descreve as regras definidas.

A motivação musicológica das regras é a seguinte: R1 e R2 separam Forró acústico (instrumentação analógica, menor energia espectral) de Forró Piseiro (eletrônico, maior energia e brilho espectral); R3 identifica Bossa Nova pelo perfil acústico mais suave (ZCR e centroide inferiores a qualquer outro gênero); R4 captura a percussão

intensa do Samba-Enredo carnavalesco via alta energia (RMS) e brilho (*roll-off*); R5 distingue Pagode do Samba comum pelo maior perfil energético; e R6 separa o Sertanejo da Bossa Nova pelo ZCR intermediário característico da viola caipira. Essas distribuições por gênero (ZCR, RMS, centroide espectral e *roll-off* no conjunto de treino) constituem a base estatística empírica das seis regras.

2.8 Ferramentas e Ambiente de Execução

A implementação foi conduzida em Python 3.11, utilizando: scikit-learn (MLP, métricas, StratifiedGroupKFold, *grid search*, importância por permutação, árvore de decisão), SciPy (Shapiro-Wilk, *t* pareado, Wilcoxon, distribuição *t* para os intervalos de confiança), pandas e NumPy (manipulação de dados), pyarrow (leitura dos arquivos Parquet) e matplotlib (visualizações). As versões exatas constam na Tabela 6. O ambiente de execução foi local (CPU, 12 núcleos), sem uso de GPU em nenhuma etapa.

O experimento repetido — cinco sementes $\times$ três condições, totalizando dez treinamentos de MLP (a camada simbólica é pós-processamento e não exige treino adicional) — consumiu **12,5 minutos** no total. Detalhes de instalação e comandos de execução constam na Seção 6.

O assistente de IA Claude Pro (Anthropic) foi utilizado como apoio técnico em etapas específicas: configuração do pipeline de MLP, implementação do controle de *data leakage*, do pipeline de explicabilidade e da camada simbólica, interpretação dos dados e suporte à análise estatística para definição das regras simbólicas. Em todas as etapas, as sugestões do assistente foram revisadas e validadas pelo autor antes de serem incorporadas.

O código-fonte completo, os *scripts* de experimento e os artefatos de resultado estão disponíveis como um pacote autocontido (Seção 6).

3 Resultados e Discussão

3.1 Impacto Quantificado do *Data Leakage* — QP1

A Tabela 2 resume a acurácia de teste nas três condições experimentais ao longo das cinco repetições, e a Tabela 3 reporta os testes de hipótese sobre os dois contrastes.

Verificação de manipulação. A medição de sobreposição confirma que o fator foi manipulado como pretendido: sob a divisão por fragmento, $99,65\% \pm 0,13$ das músicas presentes no teste também aparecem no conjunto de desenvolvimento; sob a divisão por música, a sobreposição é de $0,00\%$ em todas as repetições, verificada por *assert*. Praticamente toda música do conjunto de teste tem, portanto, pelo menos um fragmento irmão visto durante o treinamento no protocolo original — condição que torna a memorização de assinaturas de faixa não apenas possível, mas provável.

Teste de $H^{(1)}$. O MLP treinado sob divisão aleatória por fragmento — replicando literalmente o procedimento de Ribeiro et al. [4] — atinge $92,67\% \pm 0,71$ de acurácia de teste. Sob divisão estratificada por música, com os mesmos hiperparâmetros e o mesmo conjunto de *features*, a acurácia cai para $79,57\% \pm 0,87$. A diferença média pareada é de **13,10 pontos percentuais**, com intervalo de confiança de 95% em $[11,55; 14,65]$ — um intervalo inteiramente afastado de zero. O teste de Shapiro-Wilk não rejeita a normalidade das diferenças ($W=0,943$, $p=0,688$), de modo que o teste primário

Tabela 1: Regras simbólicas da camada neuro-simbólica. Fatores indicam o multiplicador aplicado à probabilidade do gênero-alvo e à dos gêneros concorrentes penalizados pela regra, respectivamente. A coluna Disp. reporta o número médio de disparos por execução, nas cinco repetições.

Regra	Alvo	Condições (treino)	Fatores (alvo/pen.)	Disp.
R1	Forró Piseiro	$RMS > 0,204$ E $SC > 2.944$	$\times 1,35 / \times 0,70$	20,2
R2	Forró	$RMS < 0,204$ E $SC \in [2.100; 2.944]$	$\times 1,20 / \times 0,80$	95,2
R3	Bossa Nova	$ZCR < 0,049$ E $SC < 2.350$	$\times 1,30 / \times 0,80$	77,0
R4	Samba-Enredo	$RMS > 0,177$ E $RO > 6.116$	$\times 1,20 / \times 0,80$	39,6
R5	Pagode	$RMS > 0,169$ E $SC > 2.894$	$\times 1,25 / \times 0,80$	33,0
R6	Sertanejo	$ZCR \in [0,049; 0,066]$ E $SC \in [2.158; 2.700]$	$\times 1,20 / \times 0,80$	42,6

Tabela 2: Acurácia de teste por cenário: média, desvio-padrão e intervalo de confiança de 95% sobre as cinco repetições.

Cenário	Média	DP (p.p.)	IC 95% (%)
Com leakage	92,67%	0,71	[91,79; 93,55]
Sem leakage (MLP puro)	79,57%	0,87	[78,49; 80,65]
Sem leakage + camada simbólica	79,59%	0,95	[78,42; 80,77]

é o t pareado: $t(4)=23,47$, $p=0,00002$. Rejeita-se $H_0^{(1)}$. O tamanho de efeito é extremo ($d=10,50$), o que é esperado em um desenho pareado no qual as diferenças são grandes e pouco variáveis: as cinco repetições produziram diferenças entre 11,66 e 14,70 p.p., sem nenhuma inversão de sinal.

O padrão por gênero (Tabela 4) é revelador: os gêneros mais beneficiados pelo vazamento são Sertanejo (+21,69 p.p.), Samba (+20,79 p.p.), Forró (+20,00 p.p.) e Bossa Nova (+19,68 p.p.) — precisamente os apontados por Ribeiro et al. [4] entre os mais difíceis de classificar. Nos gêneros de assinatura acústica mais distinta, o efeito é pequeno (Forró Piseiro, +2,42 p.p.; Samba-Enredo, +2,93 p.p.). Isso é consistente com a hipótese de que, nos gêneros difíceis, o modelo com vazamento não estava aprendendo padrões acústicos genuínos, e sim memorizando assinaturas de faixas específicas — um efeito mais pronunciado exatamente onde o sinal de gênero é mais ambíguo. O corolário prático é que o *leakage* não apenas infla a acurácia agregada: ele a infla de forma *seletiva*, mascarando justamente as fragilidades que um *benchmark* deveria expor.

Retomando QP1. Sob o protocolo corrigido, o MLP atinge $79,57\% \pm 0,87$, com IC 95% em [78,49; 80,65]. O valor reportado pelo artigo original (74,9%) **está fora desse intervalo**, e a diferença de +4,67 p.p. excede o limiar de 2 p.p. estabelecido em QP1: a replicação exata não foi atingida, e agora é possível afirmá-lo com respaldo estatístico, e não apenas por inspeção de um único número. A divergência permanece explicável: como os hiperparâmetros finais do modelo original não foram divulgados, não é possível reproduzir as condições exatas de treinamento — a Tabela 5 detalha a comparação por gênero.

Os maiores ganhos ocorrem em Forró (+23,41 p.p.), Sertanejo (+23,25 p.p.) e Samba (+10,64 p.p.) — exatamente os gêneros apontados como mais difíceis em [4]. Por outro lado, Pagode (−9,23 p.p.), Bossa Nova (−6,58 p.p.) e Funk (−6,08 p.p.) apresentaram queda, sugerindo que os hiperparâmetros encontrados por busca em grade

favoreceram as classes historicamente mais problemáticas em detrimento das mais fáceis. Vale notar que essa comparação é assimétrica em um aspecto relevante: os números do artigo original derivam de uma execução única, sem intervalo de confiança publicado, de modo que não é possível verificar se a diferença de +4,67 p.p. excede a variabilidade do próprio *benchmark* de referência.

A matriz de confusão do modelo final (Figura 1) evidencia os pares de gêneros mais frequentemente trocados, base para a análise de explicabilidade e para o desenho da camada simbólica.




Figura 1: Matriz de confusão do MLP sob o protocolo corrigido (split por música), na repetição de referência (semente 42).

3.2 Features Discriminativas: Análise Estatística e Explicabilidade — QP2

Análise estatística univariada. A análise das *features* escalares no conjunto de treino revelou os seguintes padrões: a Bossa Nova apresenta a menor média de ZCR (0,040), muito abaixo da média dos demais gêneros (Samba = 0,057; Forró = 0,068; Sertanejo = 0,055), tornando-a o gênero mais distinguível por esse parâmetro; o Samba-Enredo apresenta energia (RMS) 51% superior ao Samba comum (0,213 vs. 0,141); e o Forró Piseiro exibe brilho spectral 22% superior ao Forró acústico (3.237 Hz vs. 2.652 Hz), refletindo o uso de instrumentação eletrônica. No par Samba / Forró, a diferença entre

Tabela 3: Testes de hipótese sobre as diferenças pareadas por semente ($n=5$, $\alpha=0,05$). Shapiro-Wilk é aplicado às diferenças; p do teste primário em cada linha aparece em **negrito no texto.**

Comparação	Dif. média (p.p.)	IC 95% (p.p.)	p Shapiro	p t pareado	p Wilcoxon	d de Cohen
Com <i>leak</i> . – Sem <i>leak</i> .	+13,10	[+11,55; +14,65]	0,6875	0,00002	0,0625	10,50
Simbólica – MLP puro	+0,02	[−0,14; +0,18]	0,0133	0,71732	0,5625	0,17

Tabela 4: Acurácia média por gênero nas cinco repetições (%) e diferenças médias (p.p.). Análise exploratória: sem teste de hipótese por gênero. [†] indica sinal consistente nas cinco sementes.

Gênero	Efeito do <i>leakage</i>			Efeito da camada simbólica	
	Com <i>leak</i> .	Sem <i>leak</i> .	Δ	+ Simb.	Δ
Bossa Nova	87,20	67,52	+19,68	68,43	+0,91
Forró	93,81	73,81	+20,00	73,39	−0,43
Forró Piseiro	95,63	93,21	+2,42	93,26	+0,05
Funk	98,45	89,92	+8,53	89,97	+0,05
Pagode	90,72	81,97	+8,75	82,35	+0,37
Samba	86,13	65,34	+20,79	64,24	−1,11 [†]
Samba-Enredo	95,95	93,02	+2,93	93,07	+0,05
Sertanejo	93,44	71,75	+21,69	72,02	+0,27
Geral	92,67	79,57	+13,10	79,59	+0,02

Tabela 5: Acurácia por gênero: este trabalho (média das cinco repetições, protocolo por música) vs. artigo original.

Gênero	Original [4]	Este trab.	Δ (p.p.)
Bossa Nova	74,10%	67,52%	−6,58
Forró	50,40%	73,81%	+23,41
Forró Piseiro	93,90%	93,21%	−0,69
Funk	96,00%	89,92%	−6,08
Pagode	91,20%	81,97%	−9,23
Samba	54,70%	65,34%	+10,64
Samba-Enredo	90,10%	93,02%	+2,92
Sertanejo	48,50%	71,75%	+23,25
Geral	74,90%	79,57%	+4,67

as médias é muito inferior ao desvio-padrão intragênero em todas as *features* escalares avaliadas (no centroide espectral, por exemplo, 2.720 vs. 2.652 Hz, com desvios-padrão superiores a 600 Hz), indicando baixa separabilidade por esse tipo de descritor.

Importância por permutação (532 *features* do MLP). A análise de importância por permutação — queda de acurácia do MLP ao embaralhar cada variável, com 10 repetições por *feature* — mostra que os coeficientes MFCC dominam a lista das *features* mais importantes: os dois descritores de maior queda de acurácia ao permutar são mfcc-mean2 (queda média de 0,032) e mfcc-mean1 (0,024), seguidos pelos primeiros coeficientes do mel-espectrograma (mel-mean0/1/2, entre 0,020 e 0,021) e por tempogram-mean1 (0,017). Esse resultado é consistente com a literatura de MIR: os primeiros coeficientes MFCC capturam o envelope espectral global (timbre), o descritor mais robusto para

diferenciar famílias de instrumentação — exatamente o tipo de informação que separa, por exemplo, o timbre eletrônico do Forró Piseiro do timbre acústico do Forró.

Análise dos pares confundidos. Para os quatro pares de gêneros mais trocados pelo MLP, a comparação entre amostras corretas e confundidas aponta descritores distintos por par: Forró / Pagode (38 casos) diferencia-se sobretudo por bandas médias do mel-espectrograma (mel-mean89–92, com mel-mean90 apresentando diferença de 17,8 desvios-padrão); Bossa Nova / Forró (35 casos) por outra faixa de bandas mel (mel-mean46, 49, 51, 102, 103); Samba / Forró (26 casos) pelo primeiro coeficiente do tempogram (tempogram-mean0) combinado a MFCCs; e Pagode / Samba (48 casos, o par mais numeroso) por diferenças mais sutis concentradas em MFCCs de ordem intermediária. A recorrência de bandas mel específicas por par — e não das mesmas variáveis em todos os casos — sugere que a confusão entre gêneros tem causas acústicas distintas conforme o par considerado, não um único fator global de dificuldade.

Árvore surrogate. Uma árvore de decisão de profundidade 4 treinada para imitar as predições do MLP atinge **56,4%** de fidelidade — ou seja, reproduz pouco mais da metade das decisões do MLP usando um conjunto pequeno de regras legíveis sobre tempogram-mean10, mel-mean0/1/116/118 e mfcc-mean2, entre outras. A fidelidade moderada indica que o MLP utiliza combinações não lineares de *features* que uma árvore rasa não consegue capturar totalmente — o que é esperado e consistente com o ganho de desempenho de redes neurais sobre modelos baseados em regras simples, mas também evidencia o limite estrutural de qualquer camada puramente simbólica baseada em poucas condições lineares, tema retomado na Seção 3.3.

3.3 Extensão Neuro-Simbólica — QP3

Teste de $H^{(2)}$. O MLP puro atingiu $79,57\% \pm 0,87$ e o MLP acoplado à camada simbólica, $79,59\% \pm 0,95$ (Tabela 2). A diferença média pareada é de **+0,02 p.p.**, com intervalo de confiança de 95% em $[-0,14; +0,18]$ — um intervalo que **contém zero** e é, além disso, extremamente estreito: mesmo o limite superior do IC corresponde a menos de um quinto de ponto percentual.

Neste contraste, o teste de Shapiro-Wilk **rejeita** a normalidade das diferenças ($W=0,714$, $p=0,013$). A rejeição é explicada pela semente 7, a única das cinco com diferença negativa ($-0,20$ p.p.) e distante das demais, que se concentram entre $+0,04$ e $+0,10$ p.p. Conforme o protocolo definido na Seção 2.2, o teste primário passa a ser o Wilcoxon *signed-rank*: $W=5,0$, $p=0,5625$. **Não se rejeita $H_0^{(2)}$.** O t pareado concorda ($t(4)=0,39$, $p=0,717$), de modo que a conclusão não depende da escolha do teste. O tamanho de efeito é desprezível ($d=0,17$).

Ressalva sobre o poder do teste. O Wilcoxon *signed-rank* com $n=5$ tem p mínimo bilateral de 0,0625: ele *não pode*, por construção, rejeitar H_0 a $\alpha=0,05$, ainda que todas as cinco diferenças tenham o mesmo sinal. O resultado não significativo desse teste, isoladamente, portanto não é evidência de ausência de efeito — é apenas ausência de evidência. O argumento substantivo neste contraste vem do **intervalo de confiança**, não do valor- p : o IC de $[-0,14; +0,18]$ p.p. é estreito o bastante para descartar qualquer efeito de magnitude praticamente relevante, e não apenas para falhar em detectá-lo. Trata-se de um resultado nulo *informativo*.

O nulo agregado esconde dois efeitos opostos. A análise por gênero (Tabela 4, Figura 2) mostra que a camada simbólica não é inerte: ela intervém em $8,76\% \pm 0,28$ das amostras de teste, com 307,6 disparos médios de regra por execução. O efeito agregado nulo resulta do **cancelamento** entre um ganho e um custo:

- **Bossa Nova** é o maior beneficiado ($+0,91$ p.p. em média), consistente com R3, que explora o perfil de ZCR e centroide espectral mais baixos do gênero — a assinatura escalar mais distinta do *dataset*.
- **Samba** é o maior prejudicado ($-1,11$ p.p.) e o **único gênero cujo sinal se mantém em todas as cinco sementes**. R4 e R5 reposicionam sistematicamente amostras de Samba como Samba-Enredo ou Pagode nos casos em que o MLP está incerto: as *features* de energia (RMS) e *roll-off* têm sobreposição real entre esses três gêneros, e as regras, ao privilegiarem os alvos de maior energia, sacrificam a classe intermediária.

O ganho no Sertanejo não se sustenta. Este achado merece destaque metodológico. O Sertanejo, gênero-alvo de R6 e um dos mais difíceis do *benchmark*, apresenta ganho médio de apenas $+0,27$ p.p., com desvio-padrão de 0,38 p.p. e **sinal que se inverte entre sementes**. Em uma análise de execução única, um resultado como esse — positivo naquela semente específica — poderia facilmente ser interpretado como confirmação parcial da hipótese do *mestrado*. As cinco repetições mostram que ele é indistinguível de ruído. Esse é precisamente o tipo de conclusão espúria que a repetição com múltiplas sementes existe para prevenir, e ilustra por que o tratamento estatístico não é uma formalidade sobre resultados já conhecidos, mas uma condição para saber quais deles são reais.




Figura 2: Efeito da camada simbólica por gênero: diferença média em relação ao MLP puro nas cinco repetições, com barras de desvio-padrão. Análise exploratória, sem teste de hipótese por gênero. O Samba é o único gênero cujo sinal não se inverte em nenhuma semente.

Quanto às regras individualmente, R2 (Forró) foi a mais ativa (95,2 disparos médios), seguida de R3 (Bossa Nova) com 77,0 e R6 (Sertanejo) com 42,6. R1 (Forró Piseiro) foi a menos ativa (20,2 disparos), condizente com a alta confiança natural do MLP para esse gênero (93,21% de acurácia sem intervenção): há poucas amostras abaixo do limiar τ para a regra atuar.

3.4 Interpretação Integrada e Relação com as Hipóteses

Reunindo os três resultados desta seção, obtém-se uma leitura coerente do experimento como um todo. **QP1** confirma que a correção do protocolo de *split* é indispensável neste *dataset*: o vazamento por fragmentação de música infla a acurácia em 13,10 p.p. (IC 95%: $[11,55; 14,65]$; $p<0,001$), um efeito concentrado justamente nos gêneros mais difíceis de classificar. **QP2** mostra que, mesmo sob o protocolo corrigido, o MLP aprende principalmente a partir de coeficientes MFCC e das primeiras bandas do mel-espectrograma — descritores de timbre global — e que a confusão entre gêneros próximos tem causas acústicas específicas por par, não um fator único. **QP3** indica que a camada simbólica, construída sobre *features* escalares simples (ZCR, RMS, centroide, *roll-off*), não adiciona informação que o MLP já não capture a partir das 532 *features* de Mel + MFCC + Tempogram: nas 8,76% das amostras em que o MLP está incerto, as mesmas ambiguidades acústicas que confundem a rede também limitam a eficácia das regras.

Relação com a hipótese do *mestrado*. A hipótese de que uma camada simbólica melhora a acurácia, especialmente nos gêneros mais difíceis, **não é sustentada** pelos dados desta operacionalização específica. Não há ganho agregado ($p=0,56$; IC 95% contendo zero e estreito o bastante para descartar efeito praticamente relevante), e o ganho pontual no Sertanejo, que uma execução única sugeriria, não sobrevive à repetição.

O resultado mais informativo, contudo, não é o nulo agregado, e sim sua **decomposição**: a camada não é inerte — ela ajuda a Bossa Nova ($+0,91$ p.p.) e prejudica o Samba ($-1,11$ p.p., de forma consistente nas cinco sementes). Sobre os gêneros difíceis, portanto,

o comportamento é heterogêneo: ajuda um, prejudica outro, é indiferente ao terceiro. A hipótese do mestrado, formulada em termos de melhora uniforme nos gêneros difíceis, é refutada; mas o padrão observado sugere um refinamento produtivo — o que determina se uma regra ajuda ou atrapalha parece ser a **distinção da assinatura escalar do gênero-alvo em relação a seus concorrentes**, não a dificuldade do gênero em si. A Bossa Nova tem ZCR e centroide inequivocamente inferiores a todos os demais; o Samba ocupa uma posição intermediária em energia entre Pagode e Samba-Enredo, e é justamente essa sobreposição que as regras convertem em erro.

O achado central é que o **tipo de feature** usado pela camada simbólica é o fator limitante, não o princípio neuro-simbólico em si: a árvore *surrogate* (56,4% de fidelidade) e a análise de pares confundidos (Seção 2.6) mostram que o MLP separa gêneros por padrões distribuídos em dezenas de bandas espectrais, algo que seis regras sobre quatro variáveis escalares não conseguem replicar. Esse resultado é cientificamente válido e delimita com precisão o espaço de trabalho futuro: regras simbólicas sobre representações de nível mais alto (padrões temporais do tempogram, agregações de bandas mel) têm maior probabilidade de complementar o MLP do que regras sobre estatísticas escalares isoladas.

Quanto ao sentido dos efeitos, não houve resultados inesperados (a direção de cada achado é explicável pela literatura de MIR e pela estrutura do *dataset*). Dois pontos, porém, só se tornaram visíveis com a repetição: a **magnitude** do *data leakage* (13,10 p.p.) é maior do que se antecipava, e a degradação sistemática do Samba pela camada simbólica — invisível em uma execução isolada, onde poderia ser descartada como flutuação — mostrou-se o efeito por gênero mais estável de todo o experimento.

4 Ameaças à Validade

Validade interna. A ausência de hiperparâmetros publicados no artigo original impede atribuir com certeza toda a diferença de +4,67 p.p. (Tabela 5) à correção do protocolo de *split*: parte da diferença pode originar-se da configuração *tanh*/(200, 100) encontrada por busca em grade, que pode simplesmente ser mais adequada que a usada no artigo original. A comparação controlada da Seção 3.1, que fixa os hiperparâmetros e varia apenas a unidade de agrupamento do *split*, mitiga parcialmente essa ameaça ao isolar o efeito do *leakage*, mas não elimina a incerteza remanescente sobre o efeito isolado dos hiperparâmetros.

Uma segunda ameaça interna decorre de uma decisão de desenho declarada na Seção 2.5: a arquitetura do MLP e os limiares das regras simbólicas foram selecionados **uma única vez**, em etapa preparatória que utilizou a semente 42, e mantidos fixos nas cinco repetições. Duas consequências seguem. Primeiro, a semente 42 tem *status* ligeiramente distinto das demais, por ter participado da seleção dos fatores fixos — embora ela não se destaque das outras nos resultados observados. Segundo, e mais relevante, os intervalos de confiança reportados capturam a variabilidade do *pipeline final* (partição e treino), não a do *processo completo* de construção do modelo: um desenho que re-executasse a busca em grade a cada semente produziria intervalos mais largos. Os resultados devem, portanto, ser lidos como condicionais à arquitetura e às regras adotadas — o que é adequado às hipóteses formuladas, mas não

sustenta afirmações sobre a variabilidade da abordagem como um todo.

Validade de construto. A camada simbólica opera apenas sobre quatro *features* escalares (ZCR, RMS, centroide espectral, *roll-off*), uma fração mínima das 532 variáveis disponíveis ao MLP. O resultado nulo de QP3 mede o efeito *dessa* operacionalização específica da camada simbólica, não da abordagem neuro-simbólica em geral — regras sobre representações de mais alto nível poderiam produzir resultados distintos, como discutido na Seção 3.3.

Validade externa. O experimento está restrito ao MLP, único modelo do *benchmark* original replicado nesta etapa. Os efeitos do *data leakage* e da camada simbólica sobre os outros seis classificadores (incluindo o *ensemble Voting*) permanecem não verificados e podem diferir em magnitude, já que modelos com maior ou menor capacidade de memorização são afetados de forma diferente pelo vazamento — hipótese sugerida pela comparação entre a inflação observada aqui (13,10 p.p.) e a diferença entre o MLP original (74,9%) e o *ensemble Voting* original (83,2%, possivelmente também afetado por *leakage* em grau desconhecido).

Validade de conclusão. O desenho com cinco repetições e comparações pareadas (Seção 2.2) elimina a limitação mais séria de uma avaliação de execução única: as diferenças reportadas agora vêm acompanhadas de intervalos de confiança e testes de hipótese, e é possível distinguir efeito real de flutuação estocástica — distinção que se mostrou decisiva no caso do Sertanejo. Três limitações, porém, permanecem e devem ser declaradas.

Primeira, e principal: $n=5$ é **uma amostra pequena**. O teste de Shapiro-Wilk tem poder muito baixo nesse regime — a não rejeição da normalidade no contraste A vs. B não constitui evidência de que as diferenças *sejam* normais, apenas de que a não normalidade não foi detectável. Mais concretamente, o Wilcoxon *signed-rank* com $n=5$ tem valor- p bilateral mínimo de 0,0625 e, portanto, é *incapaz* de rejeitar H_0 a $\alpha=0,05$ sob qualquer configuração dos dados. Por essa razão, a conclusão sobre $H^{(2)}$ se apoia primariamente na estreiteza do intervalo de confiança ($[-0,14; +0,18]$ p.p.) e na concordância entre os dois testes, e não no valor- p do Wilcoxon isoladamente. Um n maior (20 a 30 sementes) permitiria testes com poder adequado e é o passo natural de extensão — viável, dado que o experimento completo consome apenas 12,5 minutos.

Segunda: as **análises por gênero são exploratórias**. Não se aplicou teste de hipótese por gênero, pois oito comparações simultâneas com $n=5$ cada exigiriam correção para múltiplas comparações (Bonferroni ou Holm) sob a qual, dado o poder disponível, nenhum efeito sobreviveria. Os padrões por gênero reportados na Seção 3 — inclusive a degradação do Samba — devem ser lidos como **geradores de hipóteses** para investigação futura, não como efeitos confirmados. O critério de consistência de sinal usado no texto é descritivo, não inferencial.

Terceira: as cinco sementes foram fixadas *a priori* e todas as execuções são reportadas, o que afasta seleção *post hoc* de resultados; mas cinco sementes não caracterizam a cauda da distribuição de desempenho. A variabilidade observada (DP entre 0,71 e 0,95 p.p.) estima a dispersão central do pipeline, não seus casos extremos.

5 Conclusão

Este trabalho executou uma replicação metodológica do MLP do *benchmark* SONBRA sob um desenho experimental explícito, com cinco repetições independentes e comparações pareadas por semente, quantificou o efeito do *data leakage* por fragmentação de música, aplicou um pipeline de explicabilidade ao modelo corrigido e avaliou o impacto de uma camada de IA simbólica acoplada como pós-processador probabilístico.

Três achados centrais emergem. Primeiro, o *data leakage* decorrente do *split* aleatório por fragmento infla a acurácia do MLP em **13,10 pontos percentuais** ($92,67\% \pm 0,71$ vs. $79,57\% \pm 0,87$; IC 95%: [11,55; 14,65]; $t(4)=23,47$, $p<0,001$), concentrando-se nos gêneros mais difíceis de classificar — evidência direta de que o modelo memoriza assinaturas de faixas específicas na ausência de controle por música de origem. O efeito é grande, consistente nas cinco repetições e sem inversão de sinal. Segundo, sob o protocolo corrigido, o MLP replicado atinge $79,57\% \pm 0,87$ de acurácia — valor cujo intervalo de confiança *exclui* os 74,9% do artigo original —, e a análise de explicabilidade mostra que essa performance apoia-se sobretudo em coeficientes MFCC e nas primeiras bandas do mel-espectrograma, descritores de timbre global.

Terceiro, a camada simbólica com seis regras sobre *features* escalares produziu efeito agregado **estatisticamente indistinguível de zero** (+0,02 p.p.; IC 95%: [-0,14; +0,18]; $p=0,56$), com intervalo estreito o bastante para descartar qualquer ganho praticamente relevante. Esse nulo, porém, não é inação: ele resulta do cancelamento entre um ganho na Bossa Nova (+0,91 p.p.) e uma degradação do Samba (-1,11 p.p.), o único efeito por gênero cujo sinal se mantém nas cinco sementes. A hipótese do mestrado — melhora, especialmente nos gêneros difíceis — não é sustentada na forma em que foi enunciada, mas o padrão observado sugere que o preditor do sucesso de uma regra é a distinção da assinatura escalar do gênero-alvo frente a seus concorrentes, não a dificuldade do gênero.

Um quarto achado é metodológico e vale registrar: o ganho no Sertanejo, que uma execução única indicaria como confirmação parcial da hipótese, não sobrevive à repetição — o sinal se inverte entre sementes. A repetição não serviu apenas para adicionar barras de erro a conclusões já formadas; ela alterou uma delas.

Como trabalho futuro, propõe-se: (i) ampliar o número de repetições para 20–30 sementes, elevando o poder dos testes e viabilizando análise formal por gênero com correção para múltiplas comparações — extensão barata, dado que o experimento completo consome 12,5 minutos; (ii) investigar regras simbólicas que operem sobre representações de nível mais alto derivadas do tempogram e de agregações de bandas mel, informadas pela análise de pares confundidos da Seção 2.6; (iii) revisar especificamente R4 e R5 à luz da degradação sistemática do Samba, tratando a sobreposição de energia entre Samba, Pagode e Samba-Enredo como o problema de desenho que ela demonstrou ser; e (iv) estender a comparação com/sem *data leakage* aos demais seis classificadores do *benchmark*, incluindo o *ensemble* Voting. Esses eixos constituem a ponte direta entre esta entrega de disciplina e o projeto de mestrado ao qual ela serve de *baseline* experimental.

6 Reprodutibilidade (Artefatos)

Todo o material necessário para reproduzir os resultados deste artigo — código, resultados brutos, análise estatística e o próprio texto — está publicado como um pacote autocontido, arquivado permanentemente no Zenodo sob o DOI 10.5281/zenodo.21403789² e disponível para navegação e contribuição no GitHub³. O DOI citado é o *concept DOI* do registro, que resolve sempre para a versão mais recente do pacote.

A única dependência externa é o *dataset* SONBRA, obtido no Zenodo⁴; ele não é redistribuído no pacote, e as instruções de obtenção e organização constam em *data/README.md*. Este trabalho utiliza exclusivamente a versão de média das características (*mean*), em formato Parquet.

6.1 Ambiente de Execução

A Tabela 6 lista as versões efetivamente utilizadas na execução aqui reportada, congeladas em *requirements.txt* a partir do ambiente que produziu *results/resultados_repeticoes.json*. Todo o pipeline foi executado localmente em CPU (12 núcleos), sem GPU e sem dependência de serviços externos além do *download* inicial do *dataset*.

Tabela 6: Versões de software utilizadas.

Componente	Versão
Python	3.11.9
pandas	3.0.3
numpy	2.4.4
scikit-learn	1.9.0
scipy	1.17.1
pyarrow	24.0.0
matplotlib	3.10.9

Registra-se uma ressalva relevante à reprodução: a execução é determinística *no mesmo ambiente*, mas versões distintas do scikit-learn podem alterar os resultados mesmo sob semente idêntica, em razão de mudanças internas no *MLPClassifier*. As versões da Tabela 6 são as necessárias para obter os números exatos aqui reportados.

6.2 Estrutura e Comandos de Execução

A Tabela 7 descreve os quatro *scripts* do pipeline e seus artefatos de saída. Reprodução completa, a partir da raiz do pacote:

```
python -m venv venv && source venv/bin/activate
pip install -r requirements.txt
python src/experimento_repeticoes.py
python src/analise_estadistica.py
python src/gerar_tabelas.py
python src/gerar_figuras.py
```

Somente o primeiro *script* requer o *dataset*; os três seguintes operam apenas sobre os arquivos JSON e permitem auditar a análise

²<https://doi.org/10.5281/zenodo.21403789>

³<https://github.com/lucasramallo/sonbra-replication-kit>

⁴<https://doi.org/10.5281/zenodo.17958966>

Tabela 7: Scripts do pipeline experimental e seus artefatos de saída.

Etapa	Script	Saída
Experimento: 5 sementes $\times$ 3 condições	src/experimento_repeticoes.py	results/resultados_repeticoes.json
Análise estatística: IC, Shapiro-Wilk, t , Wilcoxon	src/analise_estatistica.py	results/analise_estatistica.json
Tabelas do artigo	src/gerar_tabelas.py	tabelas/*.tex
Figuras do artigo	src/gerar_figuras.py	figs/*.png

estatística sem baixar os dados. O experimento completo consome **12,5 minutos**; os demais passos são instantâneos.

O motor de regras (src/camada_simbolica.py) e as seis regras de domínio com seus limiares (src/conhecimento_dominio.py) acompanham o pacote, de modo que a camada simbólica da Seção 2.7 é inspecionável e modificável sem dependências externas.

6.3 Determinismo e Rastreabilidade

As cinco sementes {42, 7, 123, 2024, 99} estão fixadas no próprio experimento_repeticoes.py e governam todos os componentes estocásticos de cada repetição — partição dos dados e inicialização/treino do MLP. O log completo da execução reportada, incluindo os tempos por semente, está em results/run_log.txt, permitindo conferir que as cinco repetições concluíram sem erro e que nenhuma foi descartada.

As tabelas deste artigo são geradas, não transcritas. O documento inclui tabelas/*.tex via \input, e esses arquivos são produzidos por gerar_tabelas.py a partir de analise_estatistica.json. Reexecutar o pipeline e recompilar o documento propaga qualquer alteração dos resultados para o texto sem intervenção manual — não há caminho pelo qual os números do artigo divirjam dos dados que os originaram.

Registra-se, por fim, que o pipeline de explicabilidade (Seção 2.6) e a Figura 1 derivam da repetição de referência (semente 42), não das cinco. A análise de explicabilidade é descritiva sobre um modelo treinado, não objeto de teste de hipótese, e por isso não é repetida — decisão coerente com o escopo das variáveis independentes declaradas na Seção 2.2.

Declaração de Uso de Inteligência Artificial Generativa

O assistente Claude Pro (Anthropic) foi utilizado como ferramenta de apoio à implementação do pipeline experimental, à revisão gramatical, à reformulação de trechos e à verificação de consistência da escrita deste artigo. Todo o conteúdo científico — incluindo hipóteses, metodologia, análise dos resultados e conclusões — é de autoria exclusiva do pesquisador, que assume responsabilidade integral pelo material aqui apresentado.

Referências

- [1] Júlia Conceição, Rosiane de Freitas, Bruno Gadelha, João Kienen, Sérgio Anders, and Brendo Cavalcante. 2020. Applying Supervised Learning Techniques to Brazilian Music Genre Classification. In *Proceedings of the 2020 XLVI Latin American Computing Conference (CLEI)*, 102–107. 10.1109/CLEI52000.2020.00019
- [2] Michaël Defferrard, Kirell Benzi, Pierre Vandergheynst, and Xavier Bresson. 2017. FMA: A Dataset for Music Analysis. *arXiv:1612.01840*.
- [3] Brian McFee, Colin Raffel, Dawen Liang, Daniel P. W. Ellis, Matt McVicar, Eric Battenberg, and Oriol Nieto. 2015. librosa: Audio and Music Signal Analysis in Python. In *Proceedings of the 14th Python in Science Conference*, Vol. 8.
- [4] Anderson Vinícius Ribeiro, João Marcos de Oliveira Santana, Marcos Abreu de Oliveira, and Cláudio Gomes. 2026. SONBRA: um dataset público e anotado para pesquisas de classificação de gêneros musicais brasileiros. *Revista Eletrônica de Iniciação Científica em Computação* 24, 1 (2026). 10.5753/reic.2026.7222
- [5] Nicolas Scaringella, Giorgio Zoia, and Daniel Mlynek. 2006. Automatic genre classification of music content: a survey. *IEEE Signal Processing Magazine* 23, 2 (2006), 133–141. 10.1109/MSP.2006.1598089
- [6] George Tzanetakis and Perry Cook. 2002. Musical genre classification of audio signals. *IEEE Transactions on Speech and Audio Processing* 10, 5 (2002), 293–302. 10.1109/TSA.2002.800560